



Analyse en Composantes Principales (ACP)



Contenu du cours

Objectifs de l'ACP


- Tableau des données et nuage des points
- choix de l'origine et normalisation des données
- Inertie du nuage des individus
- Recherche des axes principaux
- Matrice de variance-covariance
- Les Composantes principales
- Interprétation des résultats de l'ACP
- Analyse en Composantes Principales NORMÉE

Objectifs de l'ACP

- L'analyse en composantes principales (ACP ou PCA en anglais pour *principal component analysis*) est une méthode de la famille de l'analyse des données, qui consiste à transformer des variables liées entre elles (dites « corrélées ») en nouvelles variables décorréliées les unes des autres. Ces nouvelles variables sont nommées « composantes principales », ou axes principaux.
- L'un des objectifs de l'ACP sera donc de réduire le nombre de variables (trouver des espaces de dimension plus petite) afin de mieux représenter (visualiser) les individus.

Objectifs de l'ACP

- Concrètement, nous devons projeter les individus décrits dans un espace à p dimensions dans un espace à 2 ou 3 dimensions.



- o Problème dans ce cas est ce que nous allons déformer la réalité
- Le but de l'ACP sera donc de projeter au mieux les individus afin de déformer au minimum la réalité (En perdant le moins d'information)

Contenu du cours


- ❑ Objectifs de l'ACP
- ❑ Tableau des données et nuage des points
- ❑ choix de l'origine et normalisation des données
- ❑ Inertie du nuage des individus
- ❑ Recherche des axes principaux
- ❑ Matrice de variance-covariance
- ❑ Les Composantes principales
- ❑ Interprétation des résultats de l'ACP
- ❑ Analyse en Composantes Principales NORMÉE

Tableau de données et nuage des points

- ❑ Les données sont les mesures effectuées sur n unités (Individus, mesures,...) $\{w1, w2, ..., wi, ...wn\}$. Les p variables quantitatives qui représentent ces mesures sont $\{x1, x2, ..., xj, ...xp\}$.

$$X = \begin{matrix} & \begin{matrix} x_1 & x_2 & \dots & x_j & \dots & x_p \end{matrix} \\ \begin{matrix} w_1 \\ w_2 \\ \vdots \\ w_i \\ \vdots \\ w_n \end{matrix} & \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1j} & \dots & x_{1p} \\ x_{21} & x_{22} & \dots & x_{2j} & \dots & x_{2p} \\ \vdots & \vdots & \dots & \vdots & \dots & \vdots \\ x_{i1} & x_{i2} & \dots & x_{ij} & \dots & x_{ip} \\ \vdots & \vdots & \dots & \vdots & \dots & \vdots \\ x_{n1} & x_{n2} & \dots & x_{nj} & \dots & x_{np} \end{bmatrix} \end{matrix}$$

Tableau de données et nuage des points



Nuage des individus dans $\mathbb{R}^p$

Nuage des variables dans $\mathbb{R}^n$


- ❑ Ces espaces étant de dimension supérieure en général à 2 et même 3, on ne peut visualiser ces représentations.
- ❑ L'ACP permet de trouver un système d'axes tels que **les projections de ces nuages de points** sur ces axes permettent de reconstituer les positions des points les uns par rapport aux autres

c'est-à-dire avoir des images les moins déformées possible.

Contenu du cours

- ❑ Objectifs de l'ACP
- ❑ Tableau des données et nuage des points
- ❑ choix de l'origine et normalisation des données
- ❑ Inertie du nuage des individus
- ❑ Recherche des axes principaux
- ❑ Matrice de variance-covariance
- ❑ Les Composantes principales
- ❑ Interprétation des résultats de l'ACP
- ❑ Analyse en Composantes Principales NORMÉE

Choix de l'origine et normalisation des données



- ❑ O n'est pas forcément une origine satisfaisante, car si les coordonnées des points du nuage des individus sont grandes, **le nuage est éloigné de cette origine.**
- ❑ Il apparaît plus judicieux de choisir **une origine liée au nuage lui-même : le centre de gravité du nuage.**


Choix de l'origine et normalisation des données

Rappel : On appelle centre de gravité associé à $\Gamma = \{w_1, \dots, w_n\}$, le point g de coordonnées

$$G = (\overline{x_{\bullet 1}}, \overline{x_{\bullet 2}}, \dots, \overline{x_{\bullet p}})$$

où, pour tout $j \in \{1, \dots, p\}$,

$$\overline{x_{\bullet j}} = \frac{1}{n} \sum_{i=1}^n x_{ij}$$



Choix de l'origine et normalisation des données

- ❑ Prendre G comme origine, revient alors à travailler sur le tableau des données centrées X_c :

$$X_c = \begin{bmatrix} x_{11} - \overline{x_{\bullet 1}} & \cdots & x_{1j} - \overline{x_{\bullet j}} & \cdots & x_{1p} - \overline{x_{\bullet p}} \\ \vdots & & \vdots & & \vdots \\ x_{i1} - \overline{x_{\bullet 1}} & \cdots & x_{ij} - \overline{x_{\bullet j}} & \cdots & x_{ip} - \overline{x_{\bullet p}} \\ \vdots & & \vdots & & \vdots \\ x_{n1} - \overline{x_{\bullet 1}} & \cdots & x_{nj} - \overline{x_{\bullet j}} & \cdots & x_{np} - \overline{x_{\bullet p}} \end{bmatrix}$$

Choix de l'origine et normalisation des données

- ❑ Si les variables sont hétérogènes (unités différentes), comme par exemple des poids, des tailles et des âges, ...
 - o Alors on cherchera à **normaliser les variables** et à travailler sur des variables sans dimensions.
 - o La méthode, la plus couramment utilisée, est celle qui consiste à **diviser les valeurs des variables par leur écart-type**, c'est-à-dire que l'on travaille sur des **variables centrées et réduites**.

Choix de l'origine et normalisation des données

$$X_{cr} = \begin{bmatrix} \frac{x_{11} - \bar{x}_{\bullet 1}}{\sigma_1} & \dots & \frac{x_{1j} - \bar{x}_{\bullet j}}{\sigma_j} & \dots & \frac{x_{1p} - \bar{x}_{\bullet p}}{\sigma_p} \\ \vdots & & \vdots & & \vdots \\ \frac{x_{i1} - \bar{x}_{\bullet 1}}{\sigma_1} & \dots & \frac{x_{ij} - \bar{x}_{\bullet j}}{\sigma_j} & \dots & \frac{x_{ip} - \bar{x}_{\bullet p}}{\sigma_p} \\ \vdots & & \vdots & & \vdots \\ \frac{x_{n1} - \bar{x}_{\bullet 1}}{\sigma_1} & \dots & \frac{x_{nj} - \bar{x}_{\bullet j}}{\sigma_j} & \dots & \frac{x_{np} - \bar{x}_{\bullet p}}{\sigma_p} \\ \sigma_1 & & \sigma_j & & \sigma_p \end{bmatrix}$$

Où σ_j est l'écart type de la variable j donné par :

$$\sigma_j^2 = \frac{1}{n} \sum_{i=1}^n (x_{ij} - \bar{x}_{\bullet j})^2$$

Choix de l'origine et normalisation des données

- Si on veut travailler avec des **variables centrées et réduites**, L'écriture matricielle permettant de passer du tableau des valeurs centrées X_c au tableau des valeurs centrées et réduites X_{cr} de la façon suivante :

$$X_{cr} = X_c \cdot \sigma$$

Où :

$$\sigma = \begin{bmatrix} \frac{1}{\sigma_1} & \dots & 0 & \dots & 0 \\ 0 & & \vdots & & \vdots \\ \vdots & \dots & \frac{1}{\sigma_j} & \dots & \vdots \\ \vdots & & \vdots & & 0 \\ 0 & \dots & \dots & 0 & \frac{1}{\sigma_p} \end{bmatrix}$$

Choix de l'origine et normalisation des données

Exemple: Considérons la matrice de données suivante:

$$X = \begin{pmatrix} 0 & 4 & 0 \\ 1 & 3 & 1 \\ 2 & 2 & 3 \\ 3 & 1 & 1 \\ 4 & 0 & 0 \end{pmatrix}$$

- Calculer G (le centre de gravité),
- Calculer la matrice X_c des données centrées et la matrice X_{cr} de données centrées et réduites.

Choix de l'origine et normalisation des données

$$G = (2 \quad 2 \quad 1)$$

$$X_c = \begin{pmatrix} -2 & 2 & -1 \\ -1 & 1 & 0 \\ 0 & 0 & 2 \\ 1 & -1 & 0 \\ 2 & -2 & -1 \end{pmatrix}$$


$$\sigma_1 = \sqrt{\frac{1}{5} \sum_{i=1}^5 (x_{i1} - \bar{x}_{\bullet 1})^2} = \sqrt{2}$$

$$X_{cr} = \begin{pmatrix} -\sqrt{2} & \sqrt{2} & -\sqrt{\frac{5}{6}} \\ -\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} & 0 \\ 0 & 0 & 2\sqrt{\frac{5}{6}} \\ \frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2} & 0 \\ \sqrt{2} & -\sqrt{2} & -\sqrt{\frac{5}{6}} \end{pmatrix}$$

Notion de normalisation de données

Standardisation de données (aussi appelée **Z-Score normalisation**) :

- elle a pour but de ramener **la moyenne à 0 et l'écart-type à 1**.
- Plage de variation: $[-3,3]$ pour une distribution normale (loi gaussienne)



$$\mu=0$$

$$\sigma=1$$

- Technique** utilisée pour **détecter les outliers** (valeurs aberrantes)
- Utilisée pour les algorithmes qui supposent des données centrées sur le zéro, comme l'analyse en composantes principales (ACP).

Notion de normalisation de données

- Normalisation de données** (aussi appelée **Min-Max Scaling**): elle a pour but de ramener toutes **les valeurs de la variable entre 0 et 1**, tout en conservant les distances entre les valeurs.

$$X_{Normalisé} = \frac{X - X_{min}}{X_{max} - X_{min}}$$


- Normalisation de données dans un intervalle $[a,b]$**

$$X_{Normalisé} = a + \frac{(x - x_{min})(b - a)}{x_{max} - x_{min}}$$


Notion de normalisation de données

- La Standardisation et la normalisation** des données ne modifient pas la distribution des données


Exemple : Iris data



Notion de normalisation de données



Notion de normalisation de données



Notion de normalisation de données



- Pour approcher **la distribution d'une variable X de la loi normale**, nous pouvons appliquer l'une des transformations suivantes :
 - Transformation en logarithme naturel (log népérien) $\ln(X)$
 - Transformation en racine carrée : $\sqrt{X}$
 - Transformation inverse racine carrée : $\frac{1}{\sqrt{X}}$

Contenu du cours



- Objectifs de l'ACP
- Tableau des données et nuage des points
- choix de l'origine et normalisation des données
- Inertie du nuage des individus
- Recherche des axes principaux
- Matrice de variance-covariance
- Les Composantes principales
- Interprétation des résultats de l'ACP
- Analyse en Composantes Principales NORMÉE

Inertie totale du nuage des individus



- On note I_G l'inertie totale du nuage des individus par rapport au centre de gravité G :

$$I_G = \frac{1}{n} \sum_{i=1}^n d^2(w_i, G) = \frac{1}{n} \sum_{i=1}^n \sum_{j=1}^p (x_{ij} - \bar{x}_{\cdot j})^2$$

Remarque : On peut voir, en inversant l'ordre des signes sommes, que I_G peut aussi s'écrire sous la forme suivante :

$$I_G = \sum_{j=1}^p \left[\frac{1}{n} \sum_{i=1}^n (x_{ij} - \bar{x}_{\cdot j})^2 \right] = \sum_{j=1}^p \text{Var}(x_j)$$


Remarque : Dans le cas où **les variables sont centrées réduites**, la variance de chaque variable vaut 1. Alors, **l'inertie totale est alors égale à p**.

Inertie du nuage des individus par rapport à un axe passant par G



□ L'inertie du nuage des individus par rapport à un axe Δ passant par G est égale, par définition, à :

$$I_G = \frac{1}{n} \sum_{i=1}^n d^2(w_i, h_{\Delta i})$$

Où $h_{\Delta i}$ est la projection orthogonale de w_i sur l'axe Δ . Cette inertie mesure la proximité à l'axe Δ du nuage des individus.



Inertie du nuage des individus par rapport à un axe passant par G



On cherche un axe Δ passant par G d'inertie I_{Δ} **minimum** car c'est l'axe le plus proche de l'ensemble des points du nuage des individus, et donc, si l'on doit projeter ce nuage sur cet axe, c'est lui qui donnera l'image la moins déformée du nuage.

cet axe Δ minimise :

$$\frac{1}{n} \sum_{i=1}^n M_i m_i^2$$

Inertie du nuage des individus par rapport à un axe passant par G

En effet:

$$I_G = \frac{1}{n} \sum_{i=1}^n d^2(w_i, G) = \frac{1}{n} \sum_{i=1}^n GM_i^2 = \frac{1}{n} \sum_{i=1}^n (Gm_i^2 + M_i m_i^2)$$

$$I_G = \underbrace{\frac{1}{n} \sum_{i=1}^n Gm_i^2}_{\text{à maximiser l'inertie du nuage projeté}} + \underbrace{\frac{1}{n} \sum_{i=1}^n M_i m_i^2}_{\text{à minimiser carrés des distances entre points individus et leurs projections}}$$

à maximiser
l'inertie du nuage
projeté

à minimiser carrés des distances
entre points individus et leurs
projections

Contenu du cours

- Objectifs de l'ACP
- Tableau des données et nuage des points
- choix de l'origine et normalisation des données
- Inertie du nuage des individus
- Recherche des axes principaux
- Matrice de variance-covariance
- Les Composantes principales
- Interprétation des résultats de l'ACP
- Analyse en Composantes Principales NORMÉE

Recherche des axes principaux



□ En d'autres termes, on effectue un changement de repère dans $\mathbb{R}^p$ de façon à se placer dans un nouveau système de représentation où **le premier axe apporte le plus possible de l'inertie totale du nuage**, le deuxième axe le plus possible de l'inertie non prise en compte par le premier axe, et ainsi de suite.

□ La méthode **des multiplicateurs de Lagrange** peut alors être utilisée pour montrer que **L'axe Δ** pour lequel le nuage des individus a l'inertie minimum **a comme vecteur directeur unitaire le premier vecteur propre associé à la plus grande valeur propre de la matrice de covariance de X_c**

Recherche des axes principaux



□ On recherche ensuite **un deuxième axe Δ_2** orthogonal au premier **passant par G** et d'inertie minimum.

□ On trouve que Δ_2 correspond au **vecteur propre** de la **matrice de covariance de X_c** correspondant à la **deuxième plus grande valeur propre**.

□ On peut rechercher de nouveaux axes en suivant la même procédure. Les nouveaux axes sont tous **vecteurs propres** de la **matrice de covariance de X_c** correspondant aux **valeurs propres ordonnées**.

□ En conclusion, le premier axe est celui qui aura la plus **grande valeur propre λ_1** . Le deuxième axe sera celui de la **deuxième valeur propre λ_2** et ainsi de suite.

Recherche des axes principaux



■ La **matrice de covariance** étant une matrice symétrique réelle, elle possède **p vecteurs propres réels**, formant une base orthogonale de $\mathbb{R}^p$:

$$\left\{ \begin{array}{ll} \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p & \text{Valeurs propres ordonnées} \\ v^1 \perp v^2 \perp \dots \perp v^p & \text{Vecteurs propres correspondants} \\ \Delta_1 \perp \Delta_2 \perp \dots \perp \Delta_p & \text{Axes principaux} \end{array} \right.$$

Conclusion: On passera de la base orthogonale initiale des variables centrées à la **nouvelle base** orthogonale des **vecteurs propres de la matrice de covariance de X_c** . On appelle les nouveaux axes, **Axes principaux**.

Contenu du cours



- Objectifs de l'ACP
- Tableau des données et nuage des points
- choix de l'origine et normalisation des données
- Inertie du nuage des individus
- Recherche des axes principaux
- Matrice de variance-covariance
- Les Composantes principales
- Interprétation des résultats de l'ACP
- Analyse en Composantes Principales NORMÉE

Matrice de variance-covariance

□ La matrice de variance-covariance Σ est une matrice symétrique ($p \times p$) qui contient sur sa diagonale les variances des variables de X_c . Elle est donnée par:

$$\Sigma = \begin{bmatrix} \text{Var}(x_1) & \text{Cov}(x_1, x_2) & \cdots & \text{Cov}(x_1, x_j) & \cdots & \text{Cov}(x_1, x_p) \\ \text{Cov}(x_2, x_1) & \text{Var}(x_2) & \cdots & \text{Cov}(x_2, x_j) & \cdots & \text{Cov}(x_2, x_p) \\ \vdots & \vdots & \ddots & \vdots & \vdots & \vdots \\ \text{Cov}(x_j, x_1) & \text{Cov}(x_j, x_2) & \cdots & \text{Var}(x_j) & \cdots & \text{Cov}(x_j, x_p) \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(x_p, x_1) & \text{Cov}(x_p, x_2) & \cdots & \text{Cov}(x_p, x_j) & \cdots & \text{Var}(x_p) \end{bmatrix}$$

Où:

$$\text{Var}(x_j) = \frac{1}{n} \sum_{i=1}^n (x_{ij} - \bar{x}_{\bullet j})^2 \quad \text{Cov}(x_j, x_k) = \frac{1}{n} \sum_{i=1}^n (x_{ij} - \bar{x}_{\bullet j})(x_{ik} - \bar{x}_{\bullet k})$$

Matrice de variance-covariance

o Dans le cas où les poids sont égaux, la matrice de variance-covariance Σ est donnée par la forme matricielle suivante :

$$\Sigma = \frac{1}{n} X_c^T X_c$$

o Si nous introduisons aussi la matrice des poids W qui est la matrice diagonale de taille $n \times n$ donnée par :

$$W = \begin{bmatrix} p_1 & \cdots & 0 & \cdots & 0 \\ 0 & & \vdots & & \vdots \\ \vdots & \cdots & p_j & \cdots & \vdots \\ \vdots & & \vdots & & 0 \\ 0 & \cdots & \cdots & 0 & p_n \end{bmatrix}$$

o Alors, la matrice de variance-covariance Σ s'écrit:

$$\Sigma = \frac{1}{n} X_c^T W X_c$$

Eléments de l'ACP et Diagonalisation de la matrice de covariance

□ Les matrices de covariance Σ sont des matrices symétriques réelles: On peut les diagonaliser.

□ Diagonaliser la matrice Σ revient à chercher une matrice diagonale D ainsi qu'une matrice inversible P telle que :

$$\Sigma = P D P^{-1}$$

- La matrice diagonale D est formée des valeurs propres de Σ
- La matrice P est alors la matrice de changement de base
- Chaque vecteur colonne de la matrice P est un vecteur propre pour la matrice Σ

Eléments de l'ACP et Diagonalisation de la matrice de covariance

▪ Rappel valeurs propres et les vecteurs propres:

Afin d'obtenir les valeurs propres et les vecteurs propres d'une matrice symétrique, il faut procéder par étapes :

▪ Recherche des valeurs propres d'une matrice symétrique réelle M de taille $p \times p$:

- Nous disons que λ est une valeur propre de M associée au vecteur propre V si et seulement si $MV = \lambda V$
- Les valeurs propres de $\lambda_1, \lambda_2, \dots, \lambda_p$ de M sont les racines du polynôme caractéristique de M :

$$\det(M - \lambda I) = 0$$

Exemple : Recherche des valeurs propres

- Soit M la matrice symétrique suivante :

$$M = \begin{bmatrix} 7 & -4 \\ -4 & 13 \end{bmatrix}$$

$$\det(M - \lambda I) = \det \begin{pmatrix} 7-\lambda & -4 \\ -4 & 13-\lambda \end{pmatrix} = (7-\lambda)(13-\lambda) - 16 = \lambda^2 - 20\lambda + 75$$

- Nous obtenons donc les deux valeurs propres de M :

$$\lambda_1 = \frac{20+10}{2} = 15 \quad \text{et} \quad \lambda_2 = \frac{20-10}{2} = 5$$

Exemple : Recherche des vecteurs propres

- Par définition pour tout $i \in \{1, \dots, p\}$ un **vecteur propre** v_i associé à la **valeur propre** λ_i est tel que

$$Mv_i = \lambda_i v_i.$$

Pour le trouver, il faut résoudre l'équation $(M - \lambda I)x = 0$ avec $x \in \mathbb{R}^p$

- Pour notre exemple, il nous faut trouver $x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$ tel que:

- Pour $\lambda_1 = 15$, nous avons :

$$\begin{bmatrix} -8 & -4 \\ -4 & -2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 0 \Leftrightarrow \begin{cases} -8x_1 - 4x_2 = 0 \\ -4x_1 - 2x_2 = 0 \end{cases} \Leftrightarrow -2x_1 = x_2$$

Exemple : Recherche des vecteurs propres

- On prenant $x_1 = 1$, nous obtenons le vecteur propre $v_1 = \begin{bmatrix} 1 \\ -2 \end{bmatrix}$

- Pour $\lambda_2 = 5$, nous avons :

$$\begin{bmatrix} 2 & -4 \\ -4 & 8 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 0 \Leftrightarrow \begin{cases} 2x_1 - 4x_2 = 0 \\ -4x_1 + 8x_2 = 0 \end{cases} \Leftrightarrow x_1 = 2x_2$$

- On prenant $x_2 = 1$, nous obtenons le vecteur propre $v_2 = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$

Diagonalisation de la matrice de covariance

- Considérons la matrice diagonale **D obtenue à partir des valeurs propres** $\lambda_1, \lambda_2, \dots, \lambda_p$:

$$D = \begin{bmatrix} \lambda_1 & \dots & 0 & \dots & 0 \\ 0 & & \vdots & & \vdots \\ \vdots & \dots & \lambda_j & \dots & \vdots \\ \vdots & & \vdots & & 0 \\ 0 & \dots & \dots & 0 & \lambda_n \end{bmatrix}$$

Les valeurs $\lambda_1, \lambda_2, \dots, \lambda_p$ de la diagonale de D sont rangées en **ordre décroissant**

Diagonalisation de la matrice de covariance

- $V_1, \dots, V_p$ sont les **vecteurs normalisés** associés aux valeurs propres $\lambda_1, \lambda_2, \dots, \lambda_p$. ils s'obtiennent à partir des **vecteurs propres** v_i non-nul associé à λ_i en considérant

$$V_i = \frac{v_i}{\|v_i\|}$$

- La matrice de changement de base allant de la base canonique à celle donnée par les V_i **est la matrice P de taille $p \times p$ dont les colonnes sont les V_i ,**

$$P = [V_1 \quad \dots \quad V_j \quad \dots \quad V_p] = \begin{bmatrix} v_{11} & \dots & v_{1j} & \dots & v_{1p} \\ v_{21} & & v_{2j} & & v_{2p} \\ \vdots & \dots & \vdots & \dots & \vdots \\ \vdots & & \vdots & & \vdots \\ v_{p1} & \dots & v_{pj} & \dots & v_{pp} \end{bmatrix}$$

Diagonalisation de la matrice de covariance

- Nous obtenons donc la **diagonalisation** de la **matrice covariance** de Σ :

$$\Sigma = P D P^{-1} = P D P^T$$

Exemple: Reprenons les vecteurs v_1 et v_2 de notre exemple. Ils mènent aux vecteurs propres normalisés :

$$V_1 = \begin{bmatrix} \frac{1}{\sqrt{5}} \\ -2 \\ \frac{1}{\sqrt{5}} \end{bmatrix} \quad \text{et} \quad V_2 = \begin{bmatrix} \frac{2}{\sqrt{5}} \\ \frac{1}{\sqrt{5}} \end{bmatrix}$$

Notons que ces vecteurs forment bien une base orthonormée de $\mathfrak{R}^2$ car

$$\|V_1\|^2 = \|V_2\|^2 = 1 \quad \text{et} \quad V_1^T V_2 = 0$$

Diagonalisation de la matrice de covariance

- o La matrice de changement de la base P vaut donc :

$$P = \begin{bmatrix} \frac{1}{\sqrt{5}} & \frac{2}{\sqrt{5}} \\ -2 & \frac{1}{\sqrt{5}} \\ \frac{1}{\sqrt{5}} & \frac{1}{\sqrt{5}} \end{bmatrix} \quad \text{et} \quad P^{-1} = \begin{bmatrix} \frac{1}{\sqrt{5}} & \frac{-2}{\sqrt{5}} \\ \frac{2}{\sqrt{5}} & \frac{1}{\sqrt{5}} \end{bmatrix} = P^T$$

- o La diagonalisation de M s'écrit donc

$$M = P \begin{bmatrix} 15 & 0 \\ 0 & 5 \end{bmatrix} P^T$$

Contenu du cours

- Objectifs de l'ACP
- Tableau des données et nuage des points
- choix de l'origine et normalisation des données
- Inertie du nuage des individus
- Recherche des axes principaux
- Matrice de variance-covariance
- Les Composantes principales
- Interprétation des résultats de l'ACP
- Analyse en Composantes Principales NORMÉE

Les Composantes principales

- On note $C_1, C_2, \dots, C_k, \dots, C_p$ les nouvelles variables "composantes principales".
- C_k étant la nouvelle variable correspondant au nouvel axe principal associé au vecteur propre V_k
- Les C_k sont des variables "virtuelles" et sont appelées les variables principales.
- Pour $i \in \{1 \dots n\}$ et $j \in \{1 \dots p\}$, la $i^{\text{ème}}$ observation de la variables C_j est donc donnée par :

$$c_{ij} = \sum_{k=1}^p v_{kj} x_{ik} = \sum_{k=1}^p P_{kj} X_{ik} = (X_c P)_{ij}$$

Les Composantes principales

- Et de façon générale, la matrice des composantes principales est définie par :

$$C = [C_1 \ C_2 \ \dots \ C_k \ \dots \ C_p] = X_c P$$

Où

- X_c = matrice des variables centrées
- P : matrice des vecteurs propres

$$C = X_c P = \begin{bmatrix} c_{11} & c_{12} & \dots & c_{1p} \\ \vdots & \vdots & & \vdots \\ c_{n1} & c_{n1} & \dots & c_{np} \end{bmatrix}$$

Les Composantes principales

- La matrice C doit être considérée de la même manière que la matrice des données centrées X_c ,
- En effet, chaque ligne correspond aux p observations des variables $c_1, \dots, c_p$ pour un individu donné,
- chaque colonne correspond aux n observations d'une des variables principales.

$$C = \begin{bmatrix} c_{11} & c_{12} & \dots & c_{1p} \\ \vdots & \vdots & & \vdots \\ c_{n1} & c_{n2} & \dots & c_{np} \end{bmatrix}$$

- Nous avons encadré en bleu les deux premières composantes principales : Elles correspondent aux deux directions dans laquelle la variation des données est la plus importantes.

Contenu du cours

- Objectifs de l'ACP
- Tableau des données et nuage des points
- choix de l'origine et normalisation des données
- Inertie du nuage des individus
- Recherche des axes principaux
- Matrice de variance-covariance
- Les Composantes principales
- Interprétation des résultats de l'ACP
- Analyse en Composantes Principales NORMÉE

Propriétés des Composantes principales



□ La **matrice de covariance des variables principales** est la matrice diagonale **D**.

□ Autrement dit, pour tout $j; k \in \{1, \dots, p\}$ avec $j \neq k$, nous avons :

o $cov(c_j; c_k) = 0$ (les axes associés sont orthogonaux)

o $var(c_j) = \lambda_j$

$$\Sigma_{cp} = D = \begin{bmatrix} \lambda_1 & \dots & 0 & \dots & 0 \\ 0 & & \vdots & & \vdots \\ \vdots & \dots & \lambda_j & \dots & \vdots \\ \vdots & & \vdots & & 0 \\ 0 & \dots & \dots & 0 & \lambda_n \end{bmatrix}$$

Interprétation des résultats de l'ACP



□ Le rôle de l'**ACP** est de construire de **nouvelles variables** dites artificielles et de les représenter graphiquement afin de permettre à **visualiser les relations qui existent entre elles** et de décrire l'existence d'éventuels **groupes d'individus ou de variables**.

Contributions des axes à l'inertie totale

□ I_G l'inertie totale du nuage des observations initiales centrées par rapport au centre de gravité **G**

$$I_G = \sum_{j=1}^p \left[\frac{1}{n} \sum_{i=1}^n (x_{ij} - \bar{x}_{\cdot j})^2 \right] = \sum_{j=1}^p Var(x_j)$$

Interprétation des résultats de l'ACP



Donc

$$I_G = \text{trace}(\Sigma)$$

L'ACP conserve l'inertie standard, alors :

$$I_G = I_G(c_1, \dots, c_p)$$

$$= \text{trace}(\text{matrice de covariance des variables principales})$$

$$= \text{trace}(D)$$

Alors

$$I_G = \sum_{i=1}^n \lambda_i$$

Qualité de représentation du nuage des individus



□ **Contributions des axes à l'inertie totale** : C'est le pourcentage de l'inertie totale I_G associée à chaque axe. Il permet de déterminer le nombre d'axes principaux à retenir

□ La **contribution relative de l'axe j** est donnée par :

$$r_j = \frac{\lambda_j}{\lambda_1 + \lambda_2 + \dots + \lambda_p}$$

o Plus cette contribution sera grande, plus la dispersion dans la direction de la composante principale associée sera importante.

Qualité de représentation du nuage des individus

- La part d'inertie expliquée par le **plan principal** (les deux nouveaux axes) est :

$$r_2 = \frac{\lambda_1 + \lambda_2}{\lambda_1 + \lambda_2 + \dots + \lambda_p}$$

La **quantité** r_2 mesure la **qualité globale** de la représentation dans le **plan principal**, c-à-d plus r_2 sera proche de 1, meilleure sera cette représentation.


- La part d'inertie expliquée par le j premiers axes est :

$$r_j = \frac{\lambda_1 + \lambda_2 + \dots + \lambda_j}{\lambda_1 + \lambda_2 + \dots + \lambda_p}$$


On se contente souvent par les **j premiers axes** si cette valeur est **proche de 1**

Choix de dimension : combien d'axes à retenir ?

- Il est possible de se faire une idée de **ri** grâce à un graphique représentant la **décroissance des valeurs propres** $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$ appelé **éboulis des valeurs propres**



Choix de dimension : combien d'axes à retenir ?



- L'inertie expliquée par la 1ère dimension est de 67,1%, la 2ème dimension est de 17,3%...ect. En assemblant ces deux premiers pourcentage on obtient environ 84,4% d'inertie totale c-à-d une bonne qualité sur ce plan. En conclusion, on peut retenir deux axes principaux.
- Pour 3 axes, l'inertie expliquée sera de 90,7%
- Le nombre d'axes (q) est choisi de sorte que la part d'inertie expliquée r_q soit supérieure à une valeur Seuil (>50-70%) fixée a priori par l'utilisateur. C'est souvent le seul critère employé.

Interprétation des axes: Cercle des corrélations

- Afin de comprendre les **axes du plan principal**, il nous faut savoir quel rôle joue chaque **variable initiale** x_i dans la construction des **variables principales**.
- Il faut relier les variables principales aux variables initiales x_i , en calculant **le coefficient de corrélation** entre eux $\rho(x_j, C_k)$ avec j ,

$$K \in \{1; \dots; p\}$$

Nous montrons que []:

$$\rho(x_j, C_k) = \frac{\sqrt{\lambda_k}}{\sqrt{\text{Var}(x_j)}} \times v_{jk}$$

Où v_{jk} est la **jème coordonnée du vecteur propre** V_k

Interprétation des axes: Cercle des corrélations

- Etant donné que nous nous limitons ici au plan principal, chaque **variable x_j** est à mettre en relation avec **C_1 et C_2** .

- Pour chaque $j \in \{1, \dots, p\}$, nous considérons donc le point **P_j** donné par ses coordonnées,


$$(\rho(x_j, C_1), \rho(x_j, C_2)) = \left(\frac{\sqrt{\lambda_1}}{\sqrt{\text{Var}(x_j)}} \times v_{j1}, \frac{\sqrt{\lambda_2}}{\sqrt{\text{Var}(x_j)}} \times v_{j2} \right)$$

- Ces points sont tous dans le disque unité $D = \{(x; y) \in \mathbb{R}^2 \text{ tel que } x^2 + y^2 \leq 1\}$. En effet, nous avons

$$\rho(x_j, C_1)^2 + \rho(x_j, C_2)^2 \leq 1$$

Interprétation des axes: Cercle des corrélations


- **Le cercle des corrélations** est le graphique représentant les points P_j avec $j \in \{1, \dots, p\}$, sous forme de vecteurs d'origine nulle ainsi que le cercle unité



- Plus **le point sera proche du cercle**, plus la variable x_j associée aura de l'influence sur les axes du plan principal

Exemple Interprétation du cercle des corrélations

- La projection de la flèche (représentant la variable v_1) sur F_1 correspond au coefficient de corrélation entre v_1 et F_1 (0,9)
- La variable V_2 qui est corrélée négativement à F_1 (on dit aussi **anticorrélée**), c'est-à-dire que, quand V_2 croît, alors F_1 décroît. Cela se traduit par un coefficient de corrélation proche de -1
- V_3 est très peu corrélée à F_1 , mais l'est fortement à F_2 .
- V_4 , quant à elle, est très peu corrélée à la fois à F_1 et à F_2 .



Contenu du cours

- Objectifs de l'ACP
- Tableau des données et nuage des points
- choix de l'origine et normalisation des données
- Inertie du nuage des individus
- Recherche des axes principaux
- Matrice de variance-covariance
- Les Composantes principales
- Interprétation des résultats de l'ACP
- Qualité de représentation des individus

- Analyse en Composantes Principales NORMÉE

Qualité de représentation des individus

- Pour interpréter correctement **la proximité des projections** de deux individus sur un axe (plan)
- il faut s'assurer que ces individus sont bien représentés sur l'axe (plan)
- Alors, on considère **l'angle θ_i** formé entre le vecteur de **la composante principale $C_i \in \mathbb{R}_p$** et la représentation **du $i^{\text{ème}}$ individu sur l'axe (dans le plan principal)** dont les coordonnées (C_{i1}, C_{i2})
- Plus cet angle sera petit, meilleure sera la représentation du $i^{\text{ème}}$ individu dans le plan principal)

Qualité de représentation des individus

- Nous mesurons la qualité de la représentation du $i^{\text{ème}}$ individu par la quantité :

$$\cos^2(\theta_i) = \frac{(C_{ij})^2}{\sum_{j=1}^p C_{ij}^2}$$

- Par rapport à l'axe1:

$$\cos^2(\theta_i) = \frac{C_{i1}^2}{C_{i1}^2 + C_{i2}^2 + \dots + C_{ip}^2}$$

Qualité de représentation des individus

- Dans le plan, la qualité est additive:

$$\cos^2(\theta_i) = \frac{C_{i1}^2 + C_{i2}^2}{C_{i1}^2 + C_{i2}^2 + \dots + C_{ip}^2}$$

Avec :

$$\sum \cos^2(\theta_i) = 1$$

Contenu du cours

- Objectifs de l'ACP
- Tableau des données et nuage des points
- choix de l'origine et normalisation des données
- Inertie du nuage des individus
- Recherche des axes principaux
- Matrice de variance-covariance
- Les Composantes principales
- Interprétation des résultats de l'ACP
- Qualité de représentation des individus
- Analyse en Composantes Principales NORMÉE

Analyse en Composantes Principales NORMÉE



ACP simple:

- Les individus ont le même poids dans l'analyse
- Les variables sont traitées de façon symétrique (on leur fait jouer le même rôle)
- Les nouveaux axes sont issus de la matrice de covariance empirique des variables.

Reproche à l'ACP simple:

- Les anciennes variables sont hétérogènes, comme par exemple des poids, des tailles et des âges, quel sens peut-on donner aux composantes principales
- Si on change d'unités sur ces variables, on peut changer complètement les résultats de l'ACP
- Une variable contribuera d'autant plus à la confection des premiers axes, que sa variance est forte.

Analyse en Composantes Principales NORMÉE



- Pour échapper à tous ces problèmes, on travaillera avec la **matrice des données centrées réduites** X_{cr}

$$X_{cr} = \begin{bmatrix} \frac{x_{11} - \bar{x}_{\cdot 1}}{\sigma_1} & \dots & \frac{x_{1j} - \bar{x}_{\cdot j}}{\sigma_j} & \dots & \frac{x_{1p} - \bar{x}_{\cdot p}}{\sigma_p} \\ \vdots & & \vdots & & \vdots \\ \frac{x_{i1} - \bar{x}_{\cdot 1}}{\sigma_1} & \dots & \frac{x_{ij} - \bar{x}_{\cdot j}}{\sigma_j} & \dots & \frac{x_{ip} - \bar{x}_{\cdot p}}{\sigma_p} \\ \vdots & & \vdots & & \vdots \\ \frac{x_{n1} - \bar{x}_{\cdot 1}}{\sigma_1} & \dots & \frac{x_{nj} - \bar{x}_{\cdot j}}{\sigma_j} & \dots & \frac{x_{np} - \bar{x}_{\cdot p}}{\sigma_p} \\ \sigma_1 & & \sigma_j & & \sigma_p \end{bmatrix}$$

Analyse en Composantes Principales NORMÉE



- Si on calcule la matrice de covariance à partir d'un tableau de données centrées et réduites, on obtient la **matrice des corrélations**:

$$R = \begin{bmatrix} 1 & \rho(x_1, x_2) & \dots & \rho(x_1, x_j) & \dots & \rho(x_1, x_p) \\ \rho(x_2, x_1) & 1 & \dots & \rho(x_2, x_j) & \dots & \rho(x_2, x_p) \\ \vdots & \vdots & \ddots & \vdots & \vdots & \vdots \\ \rho(x_j, x_1) & \rho(x_j, x_2) & \dots & 1 & \dots & \rho(x_j, x_p) \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ \rho(x_p, x_1) & \rho(x_p, x_2) & \dots & \rho(x_p, x_j) & \dots & 1 \end{bmatrix}$$

Cette matrice n'a que des 1 sur sa diagonale et est également symétrique car

$$\rho(x_i, x_j) = \rho(x_j, x_i) \text{ pour tout } i, j \in \{1 \dots p\}$$

Analyse en Composantes Principales NORMÉE



- La **matrice de corrélation** est donnée par la forme matricielle suivante :

$$R = \frac{1}{n} X_{cr}^T X_{cr}$$

$$R = \frac{1}{n} X_{cr}^T X_{cr} = \frac{1}{n} (X_c \sigma)^T (X_c \sigma) = \frac{1}{n} \sigma^T X_c^T X_c \sigma = \sigma^T \frac{1}{n} X_c^T X_c \sigma = \sigma^T \Sigma \sigma$$

$$\sigma = \begin{bmatrix} \frac{1}{\sigma_1} & \dots & 0 & \dots & 0 \\ 0 & & \vdots & & \vdots \\ \vdots & \dots & \frac{1}{\sigma_j} & \dots & \vdots \\ \vdots & & \vdots & & 0 \\ 0 & \dots & \dots & 0 & \frac{1}{\sigma_p} \end{bmatrix}$$

Analyse en Composantes Principales NORMÉE



- Les particularités de l'ACP normée par rapport à l'ACP simple proviennent du fait que la **matrice de corrélation R n'a que des 1 sur sa diagonale principale.**
- Cela entraîne que **sa trace est toujours égale à p .** Elle est aussi égale à l'inertie totale du nuage de points
- Donc l'**inertie totale du nuage des individus** dans $\mathfrak{R}^p$ est donc **toujours égale à p** dans toute ACP normée.
- L'**inertie totale** est aussi égale à la **somme des valeurs propres**

Règle de Kaiser: on peut ne considérer comme significatives que les valeurs propres dont la valeur est supérieure à 1. **Les composantes principales retenus correspondent alors à ses valeurs propres.** Ce critère a tendance à surestimer le nombre de composantes pertinentes!